

Proiect WeaMyL

Îmbunătățirea calității, performanței și siguranței sistemului național de avertizare a fenomenelor severe imediate prin utilizarea de tehnici de machine learning aplicate pe date radar, satelitare și observații de la stații meteorologice.

Proiect finanțat prin EEA and Norway Grants sub RO-NO-2019-0133.
Contract: NO 26/2020

Consortiu

- **Babeș-Bolyai University (BBU) – promotorul proiectului**
 - expertiză în cercetarea în știința calculatoarelor și dezvoltarea modelelor de învățare automată
- **Administrația Națională de Meteorologie (NMA) – partener 1**
 - expertiză în meteorologie, cercetare și aplicații în prognoza nowcasting
- **Institutul Meteorologic Norvegian (MET) – partener 2**
 - expertiză în cercetare în meteorologie și dezvoltare software de meteorologie

Scopul proiectului

- dezvoltarea unui proces automat de generarea a avertizărilor nowcasting pentru fenomene meteorologice severe
- dezvoltarea unei baze de date meteorologice pentru extragerea inteligentă a datelor și analiza acestora

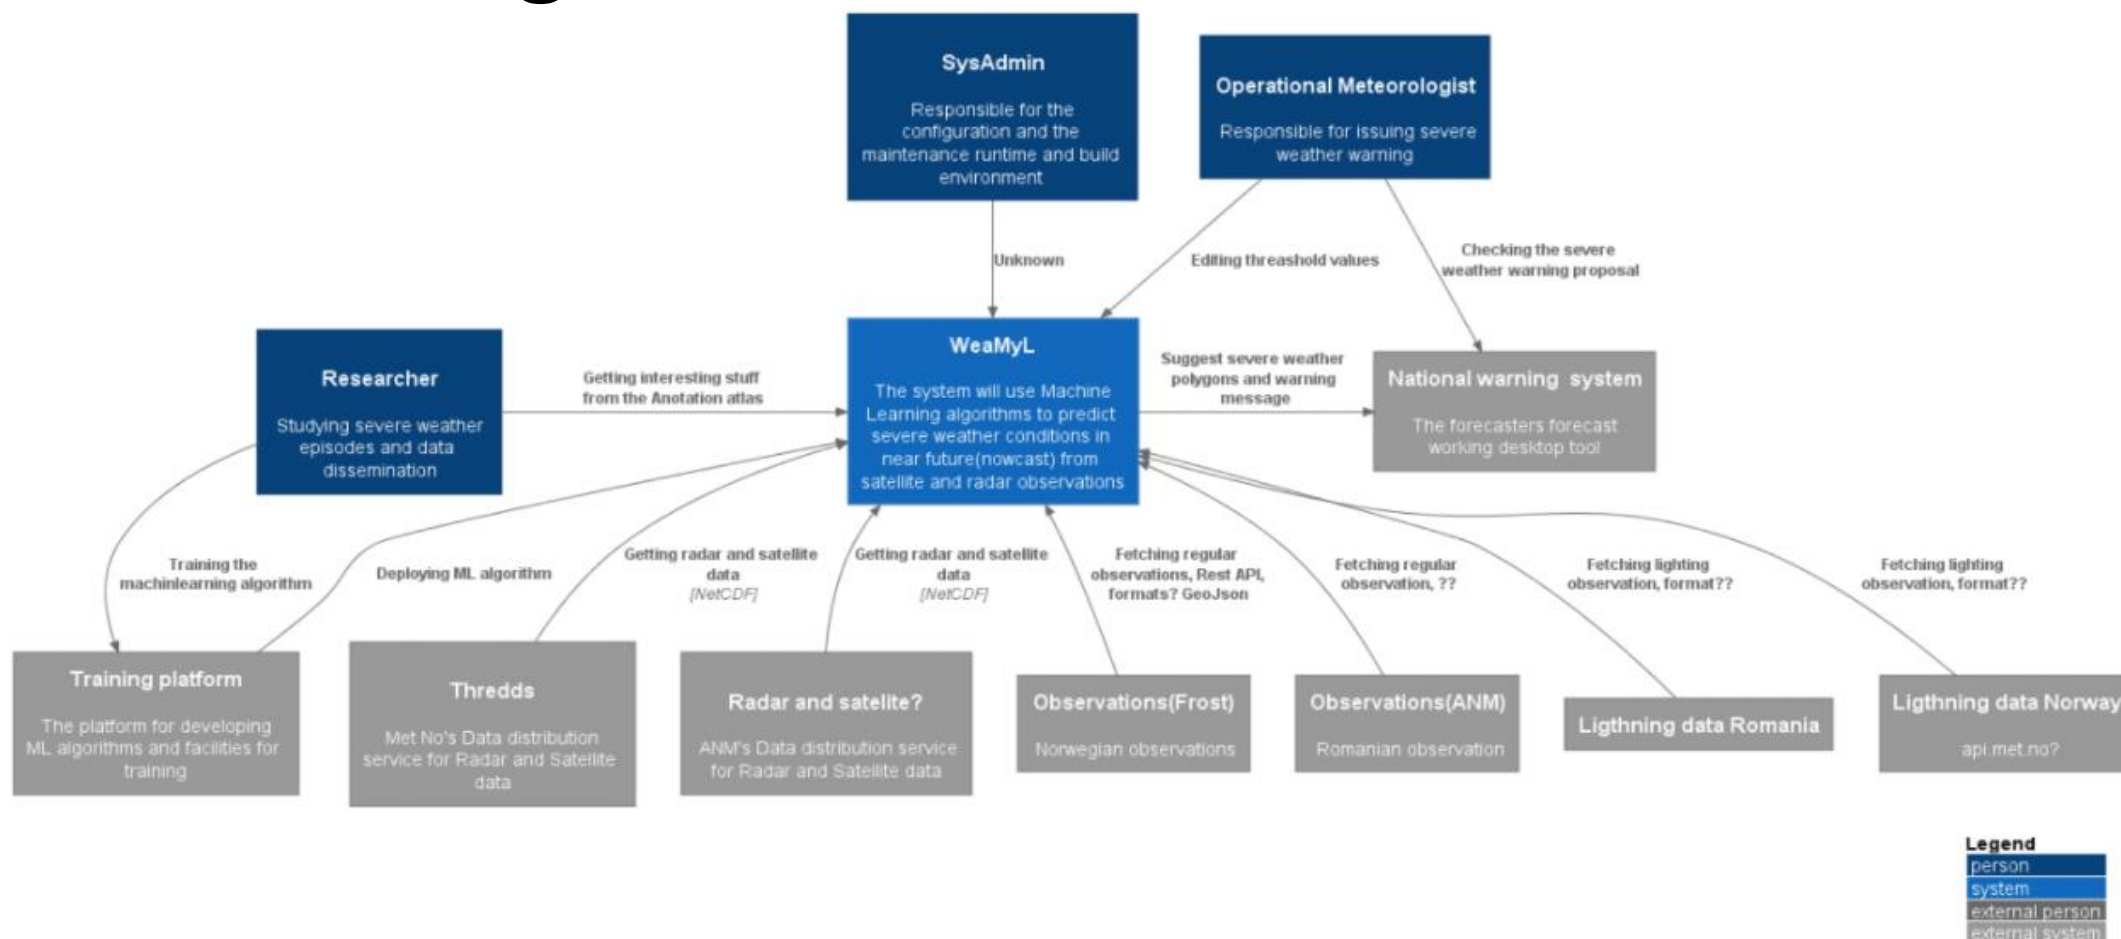
Obiectiv principal

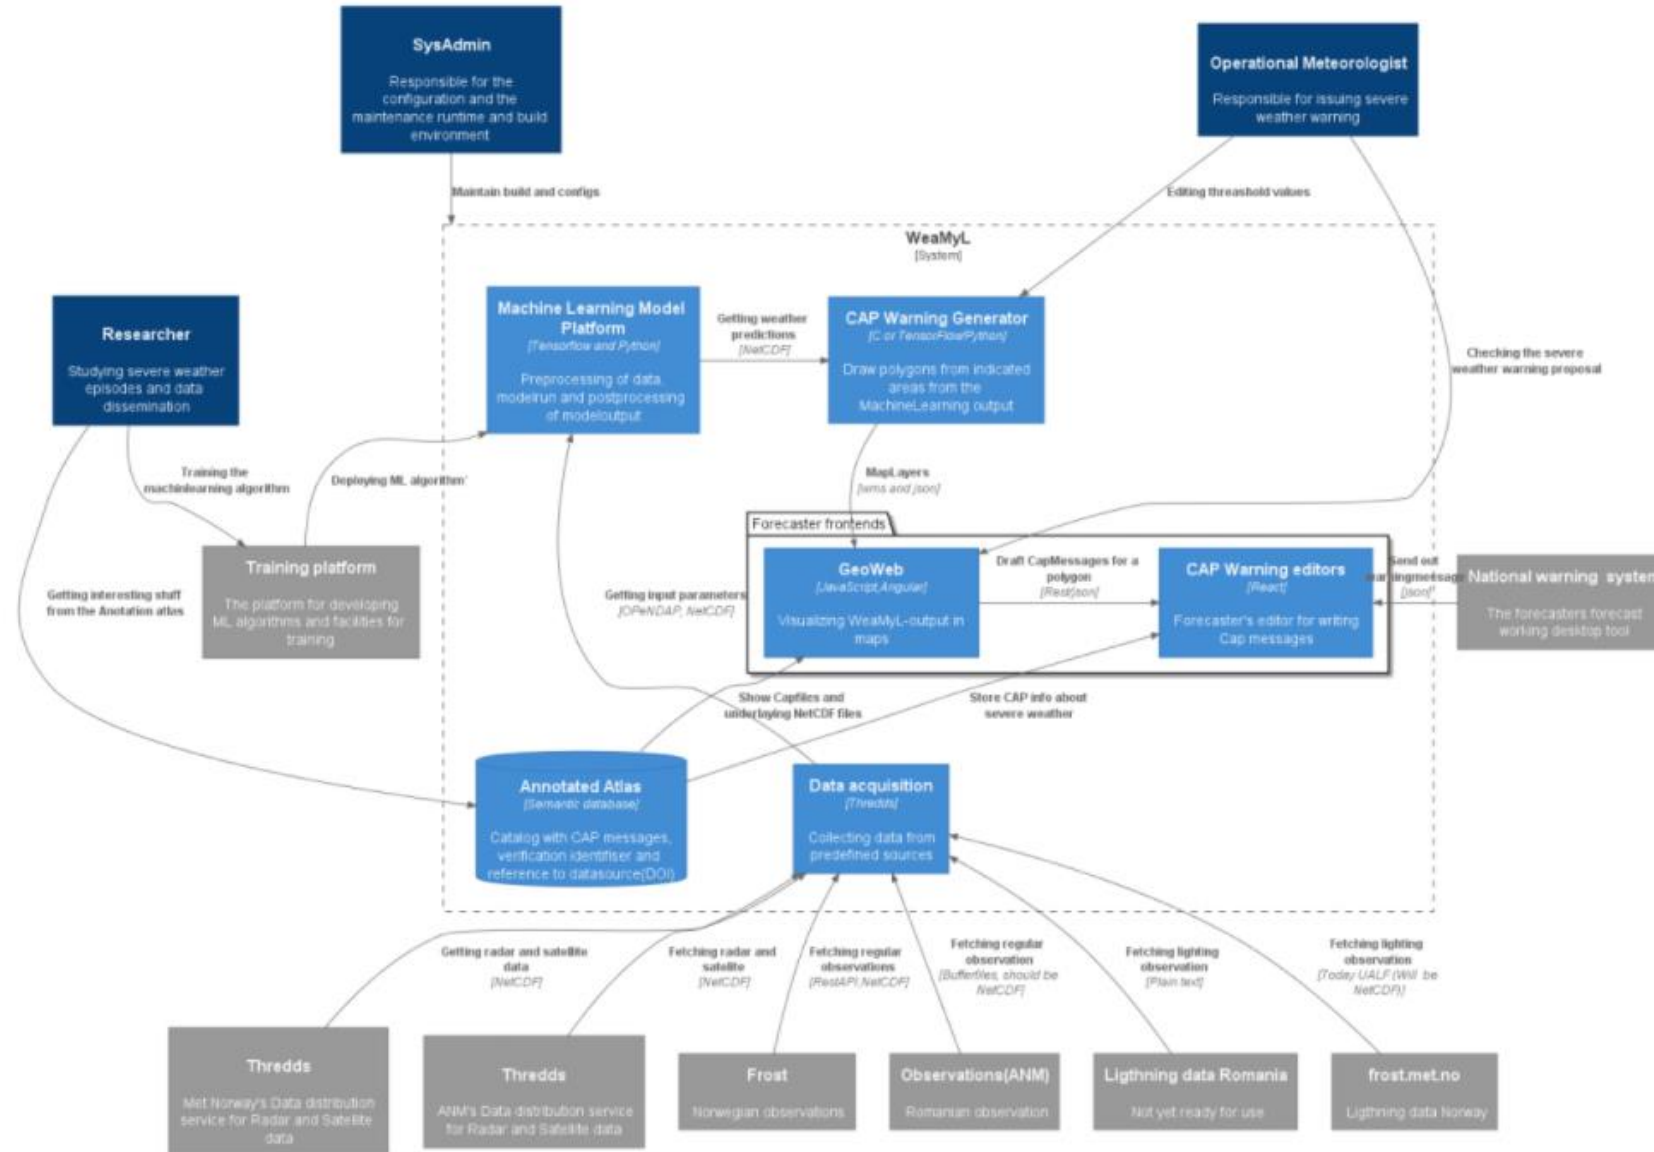
- îmbunătățirea performanței sistemului național de emiteri de avertizări nowcasting pentru fenomene convective prin aplicarea de tehnici de machine learning pe date radar, date satelitare și date de observații de la stații meteorologice
- automatizarea procesului de emiteri de avertizări nowcasting pentru fenomene convective severe

Obiective specifice

- OS1 - Dezvoltarea și validarea științifică de modele computaționale și tehnici de Machine Learning adaptate pentru meteorologie.
- OS2 - Dezvoltarea unei baze de date cu observații meteorologice adnotate și tehnici inteligente de extragere a informației în timp real. Sursă de date pentru tehnicile de învățare automată dezvoltate în cadrul proiectului (extragere date, procesare, clasificare).
- OS3 - Dezvoltarea platformei deschise WeaMyL pentru prognoza fenomenelor convective severe.
- OS4 - Integrarea platformei WeaMyL cu sistemele existente de generare de avertizări meteorologice.
- OS5 – Contribuția în domeniu prin diseminarea rezultatelor - articole științifice, website-ul proiectului, social media, ateliere de lucru, etc.

Arhitectura generală a sistemului



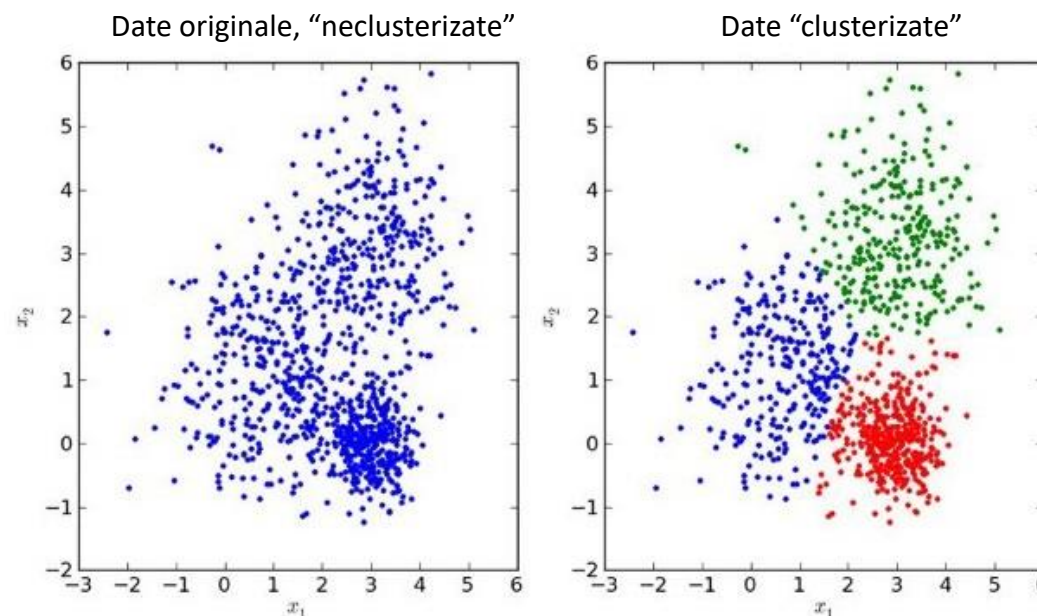


Obiectiv specific 1 - modele Machine Learning

- Dezvoltarea și validarea științifică de modele computaționale și tehnici de Machine Learning adaptate meteorologiei
 - **Modele nesupervizate** pentru determinarea datelor relevante pentru procesul de învățarea automată
 - **Modele supervizate** pentru prognozarea apariției, dezvoltării și a ariei afectate de fenomenele convective detectate de radarele meteorologice

Obiectiv specific 1 - modele Machine Learning


Modelel nesupervizate - un tip de algoritmi ML care învață din date ne-etichetate, folosiți pentru analiza și gruparea (clustering) seturilor de date




Obiectiv specific 1 - modele Machine Learning

Modele nesupervizate folosite în cadrul proiectului:

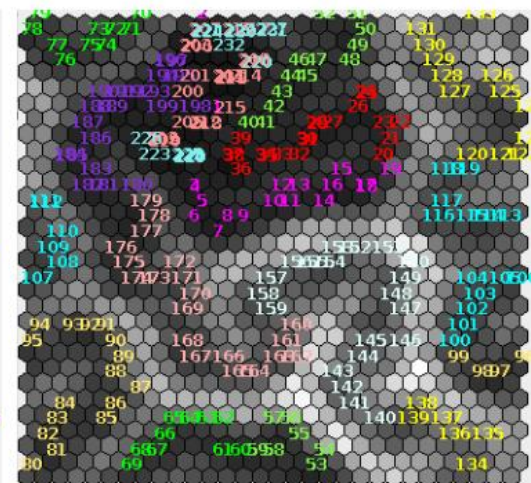
- SOM (Self-Organizing Maps)



SOM pentru 24 produse
radar



SOM pentru 13 produse radar
(R, V și VIL)




SOM pentru produsele R și VIL


Obiectiv specific 1 - modele Machine Learning

Modele nesupervizate folosite în cadrul proiectului:

- SOM (Self-Organizing Maps)




SOM pentru produsul R02 pe o
fereastră de temporală $l=1$



SOM pentru produsul R02 pe o
fereastră de temporală $l=5$

Obiectiv specific 1 - modele Machine Learning


Modelele supervizate - un tip de algoritmi ML care au ca scop construirea unei funcții de asociere a unei intrări la o ieșire pe baza unor exemple etichetate de intrări-ieșiri.




Obiectiv specific 1 - modele Machine Learning

Modele supervizate folosite în cadrul proiectului:

- Deep Artificial Neural Networks pe date radar



Date radar reale (produsul R01)



Date radar prezise de modelul
NowDeepN (produsul R01)

Obiectiv specific 1 - modele Machine Learning

Modele supervizate folosite în cadrul proiectului:


- Deep Artificial Neural Networks pe date radar

Evaluation measure	All 13 products	All R products	All V products	VIL	Improvement (%) (cleaning step)
RMSE	4.98 ± 0.06	4.97 ± 0.10	3.99 ± 0.07	5.24 ± 0.17	55%
NRMSE	$7.27\% \pm 0.09\%$	$7.10\% \pm 0.15\%$	$5.95\% \pm 0.10\%$	$7.49\% \pm 0.24\%$	55%
$RMSE_{non-zero}$	10.05 ± 0.40	9.38 ± 0.23	10.88 ± 0.71	9.10 ± 0.31	41%
$NRMSE_{non-zero}$	$14.68\% \pm 0.59\%$	$13.40\% \pm 0.33\%$	$13.24\% \pm 1.06\%$	$13.00\% \pm 0.44\%$	41%

Rezultate experimentale obținute cu modelul NowDeepN

Model	Reflectivity threshold	CSI	POD	FAR
Our NowDeepN	5	0.6475	0.8055	0.2326
	20	0.5386	0.7646	0.3543
	40	0.4290	0.6277	0.4245
TrajGRU [40]	5	0.6729 - 0.7069	0.7646 - 0.8053	0.1579 - 0.1812
	20	0.2994 - 0.3208	0.3949 - 0.4296	0.4443 - 0.4815
	40	0.0411 - 0.0549	0.0568 - 0.0859	0.7539 - 0.79

Comparație între modelul NowDeepN și un model similar folosit pentru
estimarea reflectivității radar



Serii de timp pentru produsul radar
V01 înainte și după curățarea datelor

Czibula, Gabriela; Mihai, Andrei; Mihuleț, Eugen. 2021. "NowDeepN: An Ensemble of Deep Learning Models for Weather Nowcasting Based on Radar Products' Values Prediction" Appl. Sci. 11, no. 1: 125, Special Issue Applied Machine Learning.
<https://doi.org/10.3390/app11010125>

- NowcastX version 0.0.1

Radar at 00:05



Prediction



Animație folosind un mozaic al reflectivității (composite reflectivity) pe date MET Norway

- *AutoNowP*

Nou model de clasificare binară pentru nowcasting (precipitații), bazat pe reflectivitatea radar.

AutoNowP depășeste clasificatorii similari (66%) pentru setul de date de la NMA și 50% pentru MET.

Data set	Model	CSI	TSS	POD	PPV	NPV	Spec	AUC	AUPRC
NMA	AutoNowP	0.615	0.861	0.876	0.674	0.996	0.985	0.931	0.775
		±	±	±	±	±	±	±	±
		0.018	0.012	0.012	0.017	0.001	0.002	0.006	0.013
	LR	0.672	0.752	0.757	0.857	0.992	0.996	0.876	0.807
		±	±	±	±	±	±	±	±
		0.012	0.013	0.013	0.005	0.001	0.000	0.007	0.008
	Linear SVC	0.685	0.778	0.783	0.845	0.992	0.995	0.889	0.814
		±	±	±	±	±	±	±	±
		0.012	0.007	0.007	0.015	0.000	0.000	0.003	0.009
	DT	0.574	0.725	0.734	0.724	0.991	0.990	0.862	0.729
		±	±	±	±	±	±	±	±
		0.007	0.004	0.006	0.012	0.001	0.002	0.002	0.006
	NCC	0.571	0.793	0.807	0.662	0.993	0.986	0.896	0.735
		±	±	±	±	±	±	±	±
		0.006	0.013	0.013	0.015	0.001	0.001	0.006	0.003

	NMA data	MET data	Total
WIN	21	16	37
LOSE	11	16	27
% WIN	66%	50%	58%





Figure 7. ROC curves for the classifiers from Table 4 on NMA data set.


Obiectiv specific 1 - modele Machine Learning

Modele supervizate folosite în cadrul proiectului:

- Deep Artificial Neural Networks pe date satelitare



Date reale WV62




Date prognozate ML


Obiectiv specific 1 - modele Machine Learning

Modele supervizate folosite în cadrul proiectului:

- Deep Artificial Neural Networks pe date satelitare



Date reale RGB_0014




Date prognozate ML


Obiectiv specific 1 - modele Machine Learning

Modele supervizate folosite în cadrul proiectului:

- Deep Artificial Neural Networks pe date satelitare



Date reale RGB_0016




Date prognozate ML


Obiectiv specific 1 - modele Machine Learning

Modele supervizate folosite în cadrul proiectului:

- Deep Artificial Neural Networks pe date satelitare



Date reale RGB_0017



Date prognozate ML

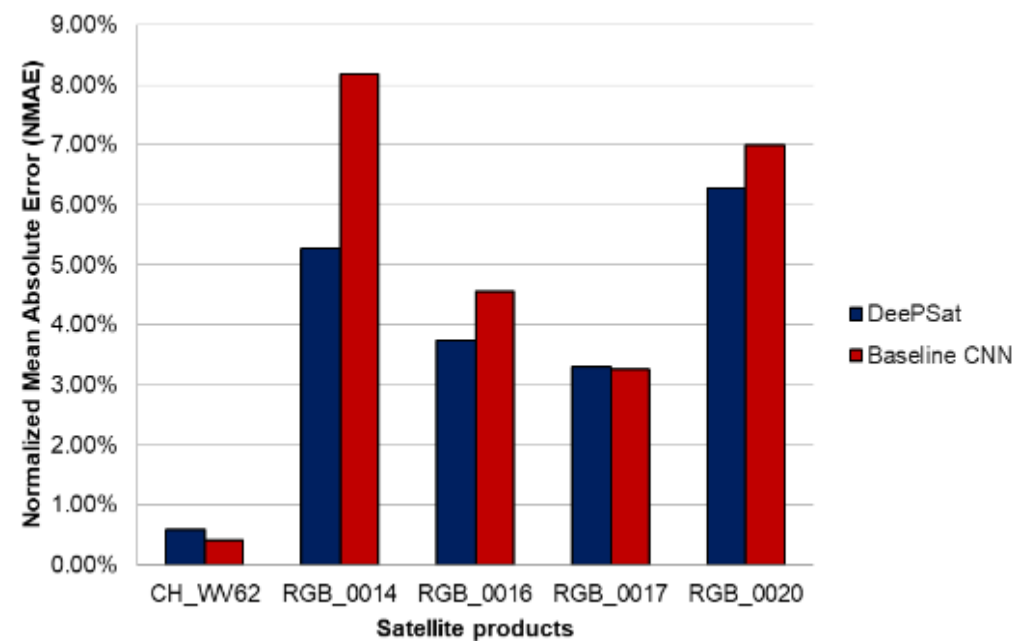
Obiectiv specific 1 - modele Machine Learning

Modele supervizate folosite în cadrul proiectului:

- Deep Artificial Neural Networks pe date satelitare

Model	Evaluation measure	CH_WV62	RGB_0014	RGB_0016	RGB_0017	RGB_0020	Average
<i>DeePSat</i>	MAE	1.464	13.456	9.557	8.414	16.006	9.779
	NMAE	0.57%	5.28%	3.75%	3.30%	6.28%	3.84%
Baseline CNN	MAE	1.024	20.846	11.623	8.31	17.281	11.925
	NMAE	0.40%	8.17%	4.56%	3.26%	6.99%	4.68%

Rezultate experimentale obținute cu modelul NowDeepN



Etapele următoare

- dezvoltarea de modele ML recurente pentru estimarea evoluției fenomenelor convective severe pe un interval de 30...60 minute;
- dezvoltarea bazei de date adnotate cuprinzând observații meteorologice (radar, satelit, observații de sol);
- testarea în mediu operativ a modelelor dezvoltate;
- dezvoltarea platformei WeaMyL cu sistemele informatice existente.

Vă mulțumim pentru atenția acordată!

Website:

<https://weamyl.met.no/>

